

Propuesta para capítulo de Juan Carlos

(Se sugieren una 25 paginas máximo, pero puede quedar en menos, como mínimo unas 19 paginas, también pueden ser poquitas mas de 25.)

Physics-Informed Quantum Optimization with Python and QuTiP: From Tunneling Barriers to Ising/QUBO Energy Landscapes

Juan Pablo, Oscar Montiel*, Moises Sanchez

***corresponding author**

Abstract.

Quantum tunneling is frequently invoked as a physical mechanism that may help quantum annealing and quantum-inspired optimization methods escape local minima in complex energy landscapes. However, the connection between tunneling through a physical potential barrier and transitions between suboptimal and optimal configurations in an optimization landscape is often introduced only at a qualitative level. This chapter develops a reproducible Python/QuTiP computational framework for analyzing this analogy from the perspective of quantum mechanics, quantum annealing, and energy-based optimization. First, one-dimensional wave-packet scattering through single and double potential barriers is simulated to compute transmission and reflection probabilities as functions of incident energy, barrier height, and barrier width. Second, resonant tunneling in double-barrier systems is studied as an example of enhanced transmission through structured energy landscapes. Third, small QUBO/Ising models are constructed and simulated with QuTiP to illustrate how local minima, global minima, and energy barriers arise in discrete optimization problems relevant to artificial intelligence applications. The chapter critically examines the strengths and limitations of mapping physical tunneling concepts onto optimization processes, emphasizing that tunneling-inspired mechanisms can provide useful intuition but do not by themselves imply universal quantum advantage. The proposed Python/QuTiP simulations provide a physics-informed and reproducible bridge between quantum tunneling, quantum annealing, and energy-based optimization models relevant to AI-oriented applications.

1. Introduction

1.1 Motivation

Explicar por qué el túnel cuántico se usa como analogía para entender quantum annealing y optimización.

1.2 Quantum tunneling and optimization: why the connection matters

Conectar barreras de potencial con barreras en paisajes de energía.

1.3 Relevance to artificial intelligence and quantum computing

Explicar que muchos problemas en AI pueden formularse como problemas de optimización: feature selection, clustering, scheduling, graph partitioning, hyperparameter search, etc.

1.4 Chapter contribution

Aquí debe aparecer claramente algo como:

This chapter contributes a reproducible Python/QuTiP framework that connects quantum barrier transmission, quantum annealing, and small Ising/QUBO optimization models.

1.5 Chapter organization

Breve descripción de las secciones.

2. Background: Quantum Tunneling and Barrier Transmission

2.1 Classical versus quantum behavior near a barrier

Comparar partícula clásica con partícula cuántica para $E < V_0$.

2.2 The one-dimensional square barrier

Definir:

$$V(x) = \begin{cases} 0, & x < 0, \\ V_0, & 0 \leq x \leq a, \\ 0, & x > a. \end{cases}$$

2.3 Transmission and reflection coefficients

Definir:

$$T = \int_{x>a} |\psi(x, t_f)|^2 dx, R = \int_{x<0} |\psi(x, t_f)|^2 dx.$$

Explicar que idealmente:

$$T + R \approx 1.$$

2.4 Dependence on energy, barrier height, and barrier width

Discutir cómo T cambia con:

- energía incidente E ;
- altura de barrera V_0 ;
- ancho de barrera a .

2.5 Double barriers and resonant tunneling

Introducir la doble barrera y explicar que pueden aparecer picos de transmisión cuando la energía coincide con estados cuasi-ligados.

3. Python/QuTiP Framework for Quantum Barrier Simulations

3.1 Spatial discretization and finite-dimensional Hilbert space

Explicar cómo pasar de una variable continua x a una malla numérica:

$$x_1, x_2, \dots, x_N.$$

3.2 Construction of the Hamiltonian

Construir:

$$\hat{H} = \frac{\hat{p}^2}{2m} + V(x).$$

En la práctica:

- operador cinético por diferencias finitas;
- operador potencial como matriz diagonal;
- Hamiltoniano como matriz $N \times N$.

3.3 Initial Gaussian wave packet

Definir:

$$\psi(x, 0) = A \exp \left[-\frac{(x - x_0)^2}{4\sigma_x^2} \right] \exp (ik_0 x).$$

Explicar el significado de:

- x_0 : posición inicial;
- σ_x : ancho espacial;
- k_0 : número de onda medio;
- $\hbar k_0$: momento medio.

3.4 Time evolution with QuTiP

Explicar el uso de `sesolve` o propagación equivalente para resolver:

$$i\hbar \frac{\partial}{\partial t} \psi(x, t) = \hat{H} \psi(x, t).$$

3.5 Numerical extraction of transmission and reflection

Definir regiones espaciales para calcular:

$$T(t_f), R(t_f).$$

3.6 Validation checks

Incluir verificaciones:

- normalización de ψ ;
- conservación de probabilidad;
- $T + R \approx 1$;
- estabilidad con respecto al tamaño de malla;

- comparación cualitativa con teoría.

4. Results I: Single-Barrier Transmission

4.1 Simulation setup

Definir parámetros base:

- masa;
- dominio espacial;
- altura V_0 ;
- ancho a ;
- energía incidente;
- posición inicial del paquete;
- tiempo total de evolución.

4.2 Wave-packet scattering dynamics

Mostrar la evolución de $|\psi(x, t)|^2$:

- antes de la barrera;
- durante la interacción;
- después de la dispersión.

4.3 Transmission as a function of incident energy

Construir curva:

$$T(E).$$

4.4 Effect of barrier height

Comparar diferentes valores de V_0 .

4.5 Effect of barrier width

Comparar diferentes valores de a .

4.6 Physical interpretation

Explicar qué enseñan los resultados sobre túnel cuántico y sensibilidad a la geometría de la barrera.

5. Results II: Double Barriers and Resonant Tunneling

5.1 Double-barrier potential

Definir una estructura tipo:

$$V(x) = \begin{cases} V_0, & x \in \text{barrier regions,} \\ 0, & \text{elsewhere.} \end{cases}$$

5.2 Quasi-bound states in the intermediate region

Explicar que la región entre barreras puede comportarse como una cavidad o pozo efectivo.

5.3 Resonant transmission peaks

Mostrar curva $T(E)$ con picos de resonancia.

5.4 Comparison with the single-barrier case

Comparar transmisión simple vs transmisión resonante.

5.5 Structured landscapes and enhanced transmission

Esta subsección sirve como puente conceptual hacia optimización: ciertas estructuras del paisaje pueden facilitar o dificultar el paso hacia regiones de menor energía.

6. From Quantum Barriers to Optimization Landscapes

6.1 Energy landscapes in optimization problems

Definir una función objetivo como paisaje de energía.

6.2 Local minima, global minima, and barriers

Explicar:

- mínimo local;
- mínimo global;
- barrera energética;

- camino de escape.

6.3 Classical escape versus tunneling-inspired escape

Comparar:

- simulated annealing: escape térmico;
- quantum annealing: fluctuaciones cuánticas y analogía de túnel.

6.4 Limits of the analogy

Importante: dejar claro que una barrera 1D no es equivalente a un espacio de Hilbert de muchos qubits.

6.5 Conceptual mapping

Aquí incluiría una tabla:

Quantum tunneling	Optimization	Quantum annealing
Potential $V(x)$	Objective function $E(z)$	Problem Hamiltonian H_P
Barrier height	Energy penalty	Cost separation
Barrier width	Hamming distance / transition difficulty	Multi-qubit transition
Transmission	Escape probability	Probability of reaching low-energy state
Reflection	Remaining trapped	Suboptimal solution

7. QUBO and Ising Models for Energy-Based Optimization

7.1 Binary optimization variables

Definir:

$$z_i \in \{0,1\}.$$

7.2 QUBO formulation

Presentar:

$$E(z) = \sum_i q_i z_i + \sum_{i < j} Q_{ij} z_i z_j.$$

7.3 Mapping from QUBO to Ising variables

Introducir:

$$s_i \in \{-1, +1\}, z_i = \frac{1 + s_i}{2}.$$

7.4 Ising Hamiltonian

Presentar:

$$H_P = \sum_i h_i \sigma_i^z + \sum_{i < j} J_{ij} \sigma_i^z \sigma_j^z.$$

7.5 Local minima in discrete energy landscapes

Explicar mínimos locales usando distancia de Hamming.

7.6 Exhaustive solution for small systems

Para $n = 4$ o $n = 5$, enumerar todos los bitstrings y calcular sus energías.

8. Python/QuTiP Simulation of a Small Quantum Annealing Model

8.1 Driver Hamiltonian

Definir:

$$H_B = - \sum_i \sigma_i^x.$$

8.2 Problem Hamiltonian

Usar el H_P construido desde el modelo Ising/QUBO.

8.3 Annealing Hamiltonian

Presentar:

$$H(s) = A(s)H_B + B(s)H_P,$$

con una opción simple:

$$A(s) = 1 - s, B(s) = s.$$

8.4 Tensor products and Pauli operators in QuTiP

Explicar cómo construir operadores de varios qubits con productos tensoriales.

8.5 Time-dependent evolution

Simular la evolución desde $s = 0$ hasta $s = 1$.

8.6 Final-state probabilities

Calcular:

$$P(z) = |\langle z | \psi(t_f) \rangle|^2.$$

8.7 Comparison with the exact optimum

Comparar:

- bitstring óptimo por búsqueda exhaustiva;
- bitstring más probable al final del annealing;
- energía final promedio;
- probabilidad de éxito.

8.8 Effect of annealing time

Estudiar qué pasa cuando cambia el tiempo total de evolución.

8.9 Minimum spectral gap

Calcular y graficar el gap entre el estado base y el primer excitado durante el annealing.

9. AI-Oriented Example: Feature Selection as a QUBO Problem

9.1 Why feature selection is an optimization problem

Explicar que en AI se buscan subconjuntos de variables relevantes y poco redundantes.

9.2 Binary encoding of selected features

Definir:

$$z_i = \begin{cases} 1, & \text{feature selected,} \\ 0, & \text{feature not selected.} \end{cases}$$

9.3 QUBO cost function for feature selection

Proponer:

$$E(z) = -\lambda_1 \sum_i r_i z_i + \lambda_2 \sum_{i < j} c_{ij} z_i z_j + \lambda_3 (\sum_i z_i - k)^2.$$

9.4 Interpretation of the terms

Explicar:

- r_i : relevancia de la característica;
- c_{ij} : redundancia entre características;
- k : número deseado de características;
- $\lambda_1, \lambda_2, \lambda_3$: pesos.

9.5 Small numerical example

Usar 4 o 5 features con valores sintéticos de relevancia y redundancia.

9.6 Ising Hamiltonian implementation in QuTiP

Mapear el QUBO a Hamiltoniano de problema.

9.7 Selected features from the final quantum state

Interpretar el bitstring más probable como subconjunto seleccionado.

9.8 Discussion of AI relevance

Aclarar que este ejemplo no reemplaza un pipeline completo de machine learning, pero muestra cómo problemas relevantes para AI pueden escribirse como modelos de energía tratables con quantum annealing.

10. Critical Discussion

10.1 What the tunneling analogy explains well

- escape de mínimos locales;
- sensibilidad a barreras;
- importancia de estructura del paisaje;
- diferencia conceptual con escape térmico.

10.2 What the analogy does not prove

- no prueba ventaja cuántica universal;
- no representa completamente un annealer real;
- no incluye ruido de hardware;
- no incluye decoherencia;
- no escala automáticamente a problemas grandes.

10.3 Physical tunneling versus many-qubit tunneling

Distinguir entre:

- túnel en coordenada continua x ;
- transiciones entre configuraciones binarias en espacio de Hilbert;
- multi-qubit tunneling.

10.4 Relevance for artificial intelligence applications

Explicar que muchos problemas de AI se formulan como optimización y que los modelos QUBO/Ising ofrecen una ruta para estudiarlos desde quantum annealing.

10.5 Reproducibility and educational value

Destacar que el valor del capítulo está en un marco reproducible Python/QuTiP.

11. Conclusions and Future Work

11.1 Main conclusions

Resumir:

- túnel físico;
- transmisión y resonancias;
- analogía con paisajes de optimización;
- QUBO/Ising;
- simulación de annealing con QuTiP;
- ejemplo de feature selection.

11.2 Limitations

Mencionar:

- sistemas pequeños;
- modelos ideales;
- ausencia de ruido;
- sin hardware real;
- sin demostración de quantum advantage.

11.3 Future directions

Proponer extensiones:

- simulated quantum annealing;
- ruido y decoherencia;
- comparación con simulated annealing;
- problemas de mayor tamaño;
- conexión con hardware de annealing;
- integración con clasificadores reales;
- comparación con Qiskit, D-Wave Ocean u otras herramientas.